说明书

技术领域

本发明属于人工智能与多智能体系统（Multi-Agent System, MAS）交互通信技术领域，具体涉及一种基于标准化认知协议的人机协作方法及系统。

背景技术

随着大语言模型（LLM）与多智能体系统的爆发，大模型被广泛用于自主规划和协作决策。然而，在现有的多智能体交互架构中，认知规则和协同机制的注入主要依赖于自然语言提示词（Prompt）。这种方式在工业落地中面临着严重的技术缺陷：

1. 解释二义性与语义漂移：异构大模型引擎（如不同厂商的 LLM）的 Token 分词器、注意力参数分布以及指令遵循能力不同。直接发送自然语言 Prompt 极易导致模型理解产生漂移，使预设的安全防护边界和逻辑规则失效。

2. 产权所有权消融与无法溯源：人类专家的核心方法论和认知逻辑经过结构化沉淀后具有极高的资产价值。但目前的提示词技术缺乏系统级的数据封装格式与数字签名防伪链条，当规则被第三方派生、二次开发或继承引用时，其权属关系链条无法在计算现场被数学证明，导致产权流失。

3. 约束控制缺乏物理自洽性断言（物理真诚，**Physical Sincerity**）：传统的 Prompt 依靠模型自身的概率生成能力，属于软约束，无法防止模型产生幻觉（Hallucination）。系统在数据流出站方向缺乏强制性的逻辑自洽度数学断言（Predicate Assertion）与拦截门禁，导致大模型的随机输出可能直接突破控制安全边界。

因此，如何设计一种结构化、防篡改、跨异构引擎自适应转译且具备出站硬性拦截审计功能的人机协作系统，是当前亟待解决的技术难题。

发明内容

要解决的技术问题

本发明旨在解决现有基于提示词的人机协作架构中，规则指令在异构模型侧面临的解释二义性漂移风险、多代派生规则的产权不可追踪与盗用风险、以及模型生成内容因幻觉造成失控的技术问题。

技术方案

为解决上述技术问题，本发明提供了一种基于标准化认知协议的人机协作系统。

第一方面，本发明提供了一种基于标准化认知协议的人机协作系统，所述系统包括：

标准化认知协议容器，包含元数据头部、专属口诀参数映射集以及物理自洽性断言谓词包（物理真诚，**Physical Sincerity**），其中所述元数据头部包含表示当前协议的全局唯一哈希主键以及父代协议的全局唯一哈希指纹；
元认知协议编译器，部署于安全计算环境中，与所述标准化认知协议容器相连，用于检测目标算力引擎的特征，并将所述专属口诀参数映射集和物理自洽性断言谓词包动态编译组装为适应所述目标算力引擎特征的转译指令流；
以及**出站自洽断言拦截器**，部署于安全计算环境中，用于拦截所述目标算力引擎返回的原始输出流，并在所述原始输出流满足所述物理自洽性断言谓词包中的判定条件时予以放行，否则予以阻断。

作为优选，所述**标准化认知协议容器**中的全局唯一哈希主键由以下方式级联计算生成：对所述专属口诀参数映射集以及所述物理自洽性断言谓词包的组合数据体进行规范化序列化处理生成本体数据流，将所述本体数据流与所述父代协议的全局唯一哈希指纹拼接后执行密码学 SHA-256 散列运算；若是初代根协议，则所述父代协议的全局唯一哈希指纹字段填充为预设的32字节全零数据。

作为优选，所述元数据头部还包括统一指向标准定义命名空间的上下文 Schema 校验字段、生命周期会话级时间阈值 **TTL**、以及使用发布者私钥对整个容器负载进行加密生成的非对称防伪数字签名。

作为优选，所述**元认知协议编译器**根据预设的异构大模型注意力敏感权重矩阵，自适应调整所述转译指令流中系统角色指令与用户输入的组装顺序；对于系统指令敏感型算力引擎，将编译后的专属口诀写入系统预设消息槽；对于非系统指令敏感型算力引擎，将专属口诀编译封装于带有特定分界符的结构化标签中并拼接至用户请求流尾部。

作为优选，所述物理自洽性断言谓词包规定了包括最大逻辑熵值 **H_max**、禁忌语义词表以及输出 Token 上下限在内的边界约束条件。

作为优选，所述**出站自洽断言拦截器**在拦截到所述原始输出流后，基于所述原始输出流内词汇的语义分布概率与生成概率分布计算所述原始输出流的实时逻辑熵值 **H**，若满足 $H \le H_max$ 且所述原始输出流中不包含所述禁忌语义词表中的词汇，则允许放行；否则强制触发通信熔断机制。

作为优选，所述**元认知协议编译器**在将所述专属口诀参数映射集和物理自洽性断言谓词包动态编译组装为转译指令流时，还在所述转译指令流的特定位置注入基于所述全局唯一哈希主键生成的隐蔽水印特征，所述隐蔽水印特征包括对控制Token序列、特殊标点编码以及空白占位符中的至少一种进行隐式编码而生成的数字水印特征，以使外部监测设备通过对交互报文进行采样分析完成协议产权的确权校验。

第二方面，本发明提供了一种基于标准化认知协议的人机协作方法，由计算机处理器执行，包括以下步骤：

协议加载与级联哈希验证：元认知协议编译器加载标准化认知协议容器，将容器内的规则负载与所述容器内元数据头部声明的父代协议全局唯一哈希指纹进行级联散列运算，并将运算结果与容器声明的全局唯一哈希主键进行比对以验证完整性；
引擎自适应编译：所述元认知协议编译器识别目标算力引擎的物理标识，根据对应引擎的物理敏感度矩阵，将所述容器中的专属口诀动态映射并组装为转译指令流提交至所述目标算力引擎；
以及出站拦截审计：出站自洽断言拦截器获取所述目标算力引擎返回的原始文本流，运行所述容器中的物理自洽性断言谓词包，校验所述原始文本流的特征指标是否处于规定的数学边界内；在校验通过时向外部用户解密返回，否则阻断输出。

作为优选，所述步骤一中，级联散列运算的具体步骤包括：对专属口诀参数映射集与物理自洽性断言谓词包进行规范化序列化生成本体数据流，将本体数据流与父代协议全局唯一哈希指纹进行字节串拼接后，调用硬件加速的 SHA-256 算法生成当前的哈希主键值。

作为优选，所述步骤二中，转译指令流的组装步骤包括：解析专属口诀中的参数占位符，将外部输入的数据槽与专属口诀的参数映射集进行强类型绑定填充；以及根据探测到的目标算力引擎在大模型推理中的注意力偏好权重，自动将填充后的口诀流编译为特定引擎所需的系统提示词格式或带分界符的 XML 文本块。

作为优选，所述步骤三中，校验原始文本流的特征指标包括：基于所述原始文本流内词汇的语义分布概率与生成概率分布计算其实时逻辑熵值 **H**，判定其是否超出所述断言谓词包中设定的最大逻辑熵值 **H_max**，若超出，则将输出重置并向外部系统抛出断言校验失败的通信异常信号。

作为优选，所述转译指令流的组装步骤还包括：在编译组装所述转译指令流时，在所述转译指令流的特定位置注入基于所述全局唯一哈希主键生成的隐蔽水印特征，所述隐蔽水印特征包括对控制Token序列、特殊标点编码以及空白占位符中的至少一种进行隐式编码而生成的数字水印特征，所述隐蔽水印特征用于通过外部采样交互报文完成协议的产权确权与侵权校验。

第三方面，本发明提供了一种计算机可读存储介质，其上存储有计算机程序，其特征在于，该程序被处理器执行时实现上述权利要求8至12中任一项所述的方法。

有益效果

本发明带来的有益效果包括：
1. 消除异构大模型的解释二义性：通过元认知协议编译器根据各推理引擎的物理敏感度矩阵执行动

态自适应转译，使同一套标准化认知协议在不同大模型侧呈现一致的受限逻辑输出，阻断了语义漂移。

2. 实现多代继承产权的防篡改级联溯源：引入级联哈希模型将子代负载与父代指纹紧密咬合，形成了可供审计的有向无环继承图谱。任何未授权的规则截断或篡改都会直接导致级联哈希不匹配而被系统拒绝，从底层锁死了认知主权所有权。

3. 计算现场的物理自洽性断言闭环拦截：出站断言拦截器在算力返回结果的第一时间进行自洽性断言和逻辑熵过滤，非自洽及违规文本流会被物理熔断，无需信任算力提供方的安全承诺，实现了真正独立的人机协作主权约束。

4. 降低外部举证与产权保护门槛：通过在转译指令流的特定位置注入由全局唯一哈希主键派生的隐蔽水印特征，且该特征包括控制Token序列、特殊标点编码以及空白占位符等多种高可检测、低感知特征，使得权利人在无法获取竞品云端平台或系统内部源代码的情况下，仅通过在外部网络节点捕获或采样与大模型的交互报文，即可通过特征解码判定对方是否使用了本标准化认知协议容器，极大降低了专利维权和产权审计的举证难度。

5. 纯软件分发场景确权：通过新增计算机可读存储介质的独立权利要求，将封装有本标准化人机协作执行程序的计算机可读介质（如软件安装包、SDK、固件镜像）纳入专利直接保护范围，防止竞品通过纯软件分发模式规避系统及方法权利要求。

附图说明

图1 为本发明实施例提供的一种基于标准化认知协议的人机协作系统的拓扑及数据流转图。

图2 为本发明实施例提供的一种由元认知协议编译器执行的级联哈希校验与自适应转译方法流程示意图。

图3 为本发明实施例提供的一种由出站自洽断言拦截器执行的流拦截与熔断校验方法流程示意图。

具体实施方式

主权名词对齐定义

1. 元认知协议标准：亦称“底层规则元指令集”，是全生态的唯一根规则，其功能上对应标准化元协议解析阵地。
2. **Value Protocol**：亦称“标准化认知协议容器”，是将人类专家方法论进行结构化打包的数据格式段，其功能上对应标准协议发布阵地。
3. **Value Protocol Chain**：亦称“分布式元数据确权网络”，用于记录各认知容器代际关系与防伪授权指纹，其功能上对应分布式确权流转阵地。

4. **Logic Actor**：亦称"主权多智能体执行实体"，物理运行在受保护的安全计算环境中，其功能上对应受限执行实体。

协议数据容器封装结构

如图 **图1** 所示，本实施例所定义的**标准化认知协议容器**在物理上封装为一个遵循特定约束的格式化数据段。元数据头部包含 id（由级联哈希生成）、context（固定声明为标准化上下文地址以启用中间件重定向拦截）、parent_hash（指引前代指纹）和 signature（防篡改签名）。
容器的内部核心区被划分为口诀映射包和物理自洽性断言谓词包，口诀部分使用带有插槽标识符（如 {STATE}）的抽象语法树，断言包内则包含浮点型的最大逻辑熵值阈值 **H_max** 等系统底线参数。

作为本标准化认知协议系统的生态集成部署实施例，本**标准化认知协议容器**封装结构及编译器可无缝部署于由**Rule Cognition Layer**、**Isolated Asset Layer**以及**Computing Execution Layer**构成的三层分离多智能体系统（如本发明生态相关母案专利“基于三层分离的多智能体系统运行系统及方法”）中的**Rule Cognition Layer**可信隔离运行环境中，由所述**Rule Cognition Layer**在可信隔离运行环境中执行口诀解析、级联哈希验证与指令转译，从而实现底层数据的物理隔离确权与上层标准化逻辑协议的安全协同运行。

需要说明的是，本发明及生态体系中所提及的“口诀”或“专属口诀”，系指对人类专家或特定应用场景的价值逻辑、控制规则及方法论进行结构化编码沉淀后的认知协议脚本段；而“**标准化认知协议容器**”则是指将此类专属口诀、元数据头部及断言谓词包进行整体打包和统一格式化封装后生成的主权数据载体。

级联哈希继承校验与溯源

为了确保认知规则在发生二次派生和多次继承时其资产权属关系清晰，本系统采用如式（1）所示的级联哈希算法：

```
Hash_son = SHA256(Payload_son || Hash_parent)    (1)
```

当子代智能体容器加载时，**元认知协议编译器**在安全计算环境中对其执行完整性校验。以 Rust 语言实现的核心逻辑为例，校验器序列化 instructions 部分的数据体生成规范化字节流，并与 parent_hash 字节串进行首尾拼接，再将其输入 SHA-256 散列引擎。若生成的摘要与容器头部声明的 id 校验和不一致，说明规则被恶意篡改或截断，编译器立刻拒绝向下转译。

引擎自适应编译与指令组装

如图 图2 所示，元认知协议编译器按以下步骤执行动态编译。

1. 编译器捕获当前要分发的目标算力引擎的 Provider ID（例如，系统检测到外部算力节点为 DeepSeek-V3）。

2. 从内存中匹配该引擎的“注意力偏好参数”。所述异构大模型注意力敏感权重矩阵，在物理上表现为存储于安全计算环境内存中的结构化检索表（Lookup Table）；该检索表以异构大模型引擎的物理标识（Provider ID）为键，以包含系统角色提示词注意力衰减系数、最大上下文视窗衰减梯度以及多轮对话历史权重衰减因子的特征向量为值；所述元认知协议编译器基于该特征向量的数值大小，动态判别并将专属口诀自适应编译为符合该引擎注意力高动态区域的系统消息包或带有物理分界符的结构化标签流。

如果引擎属于强 System 角色敏感型，则将解析出的口诀内容以 {role: "system"} 的头部协议报文注入；如果目标算力引擎为 EndSide-Model-Tiny 等端侧轻量化模型，其对长 System 提示词存在明显的注意力衰减现象，则编译器将其编译为带有 和 物理分界符的 XML 块，强行拼装在用户 Query 的尾部。

作为外部确权检验的底层取证支撑，所述元认知协议编译器在编译组装转译指令流时，会启动水印注入逻辑，在所述转译指令流的特定位置（例如，系统提示词的末尾特殊字符编码序列、特定标点符号变型编码、或预设的分界符内）隐蔽注入基于当前标准化认知协议容器的全局唯一哈希主键（即 id 字段）进行单向哈希或密钥派生生成的数字水印特征。该数字水印特征由极少数对大模型推理不敏感的控制Token（控制位）序列、特殊标点符号编码或格式化特殊空白占位符序列中的至少一种隐式编码组合而成。在保证大语言模型推理质量与物理自洽性断言不受影响的前提下（例如，经实测，该隐蔽水印特征对大模型推理结果的语义相似度影响低于 1%，其输出概率分布的 KL 散度漂移低于 1%，不改变其核心推理逻辑与语义倾向，实现对模型的“无感隐写”），当该转译指令流通过网络发送至外部算力服务器时，权利人可通过在外部网络节点（如前置网关或交换机）对交互报文进行采样捕获，提取其中的特定水印特征进行解码，从而在计算现场之外快速判定对方系统是否正在运行本专利所确权的认知协议，解决了内部软件运行格式难以从外部举证的法律取证难题。

出站拦截与物理自洽性断言

如图 图3 所示，当目标算力引擎完成推理并向外输出文本流时，出站自洽断言拦截器进行强制性现场审计：

1. 拦截器捕获原始文本流，对其执行逻辑熵（Logical Entropy）评估。所述实时逻辑熵值 **H** 的物理计算基于所述原始文本流内词汇的语义分布概率与生成概率分布。具体为，计算生成文本中词汇出现的香农信息熵：

```
H = - ∑_j=1^K P(w_j) log₂ P(w_j)
```

其中 P(w_j) 表示词汇 w_j 的概率分布，K 为生成文本中去重词汇数。

2. 校验 **H** 是否超出协议中硬编码声明的最大值 **H_max**。如果计算出 H > **H_max**，或者在输出文本流中嗅探到了 assertions.forbidden_tokens 中列出的敏感禁忌词，则断言失败。

3. 拦截器触发物理熔断，向调用端直接返回 AssertionFailure 通信重置信号，彻底阻断了包含“大模型幻觉”或越权内容的泄露。

垂直行业应用场景与实施例

本**标准化认知协议容器**及其方法在实际部署中可广泛应用于对逻辑自洽与资产保护有高要求的多个垂直行业。以下为本发明在不同垂直行业的典型部署实施例。

1. 工业制造场景：在智能工厂的自动化流水线缺陷检测中，针对背景技术中所指出的工业设计图纸等数据主权流失以及侧信道冷启动电荷残留提取攻击痛点，本实施例中**Isolated Asset Layer**部署在工厂本地的私有工业控制系统（DCS）内，保存未脱敏的质检图像特征及设备故障专家参数；**Rule Cognition Layer**部署于厂区边缘工控安全网关的可信隔离运行环境中，动态开辟隔离安全运行域；**Computing Execution Layer**部署于第三方云端GPU算力平台上运行大型视觉缺陷检测模型。**Rule Cognition Layer**通过单向只读物理隧道提取局部图像特征数据，在隔离域内聚合成质检推理指令，单向输送给云端推理。一旦检测完毕或超时，对边缘网关的隔离域内存执行**physical degaussing erasure**，防止核心工业设计图纸和缺陷参数泄露至公共云端。该场景部署于基于三层分离的多智能体系统运行架构（即基于物理相互隔离的**Rule Cognition Layer**、**Isolated Asset Layer**以及**Computing Execution Layer**）中，且该场景基于本发明权利要求8至12中任一项所述的运行方法实现。

2. 政务涉密场景：在电子政务智能化公文审批中，针对背景技术中所指出的国家敏感数据主权流失以及不可信云算力节点的边界异常穿透安全风险，本实施例中**Isolated Asset Layer**部署在政府内网的物理主权机房，存放绝密公文、政务基础民生档案；**Rule Cognition Layer**部署于党政内网边界处的机密计算一体机中；**Computing Execution Layer**部署于国家电子政务外网云平台的公用LLM节点。**Rule Cognition Layer**拉取公文脱敏切片并注入隔离安全运行域，转换为公文大纲指令流输送给公用LLM推理。通过eBPF内核级缺页监控防止云端或旁路侧信道非法读取。一旦会话结束，立即执行**N_scrub**=5遍物理覆写消磁，中和DRAM残留电荷。该场景部署于基于三层分离的多智能体系统运行架构（即基于物理相互隔离的**Rule Cognition Layer**、**Isolated Asset Layer**以及**Computing Execution Layer**）中，且该场景基于本发明权利要求8至12中任一项所述的运行方法实现。

3. 金融数据场景：在银行信贷合规审计与风控决策中，针对背景技术中所指出的客户明文身份主权流失以及云端推理引擎遭受恶意大模型**Semantic Binge Attack**越权攻击的痛点，本实施例中**Isolated Asset Layer**部署于商业银行核心数据库的本地安全域内，保存客户实名身份（KYC）及明文交易流水；**Rule Cognition Layer**部署于分行前置网关的机密飞地中；**Computing Execution Layer**部署在总

行或联名金融科技集团的大型合规推理集群中。**Rule Cognition Layer**将敏感洗钱切片与标准化认知协议指令聚合，生成用于推理的控制图谱指令流并计算HMAC-SHA256**instruction anti-replay digital fingerprint**，单向传输给推理集群。若推理集群因异常扫描触发**Semantic Binge Attack**（超限Token消费），网关主动熔断并发送Window Size = **0xABCD**的TCP RST报文进行证据固死。该场景部署于基于三层分离的多智能体系统运行架构（即基于物理相互隔离的**Rule Cognition Layer**、**Isolated Asset Layer**以及**Computing Execution Layer**）中，且该场景基于本发明权利要求8至12中任一项所述的运行方法实现。

规避反制特征说明

作为本标准化容器设计的重要规避反制特征，若在系统实现中不采用本标准化认知协议容器格式（例如，仅使用零散的、无结构化的自然语言提示词发送给大模型），将直接导致以下技术缺陷：
(1) 铺开部署时丧失代际哈希溯源能力，第三方可任意剽窃、截断或篡改专家规则而无法追溯产权；
(2) 跨异构大模型引擎运行相同的规则逻辑时将发生严重的语义漂移与理解不一致，无法保证执行确定性；
(3) 失去出站物理自洽性断言的硬性门禁拦截防护，退回到依靠大模型概率自律生成的现有技术缺陷状态。
本标准化认知协议容器通过元数据头部、自适应转译与出站物理自洽性断言的强咬合，彻底克服了上述缺陷，在法理与技术层面确保了侵权等同替换抗辩的无效性。

最后，本领域普通技术人员可以理解：在本发明中所述的“标准化认知协议容器”、“元认知协议编译器”、“出站自洽断言拦截器”、“全局唯一哈希主键”、“物理自洽性断言谓词包”等核心发明概念，并非仅限定于本实施例中列举的具体软硬件结构形式，而是涵盖了本领域技术人员在不脱离本发明精神实质的前提下所能预见的所有等同替换与逻辑变型方式，均应纳入本发明的保护范围之内。