# 说明书

## 技术领域

本发明属于分布式人工智能、智能合约、因果推断及多智能体协同安全领域，具体涉及一种基于“需求-方案-行为-效果”时序因果对齐校验、滑动窗口动态审计权重积分演化计算、以及可信沙箱隐私脱敏签名验证的多智能体真诚度审计系统及方法。

## 背景技术

随着多智能体在工业协作和日常助手领域的广泛应用，智能体之间通过调用彼此的价值协议来完成复杂的长链任务。在此类协作中，按效果付费逐渐成为主流清算方式。然而，现有的协作网络面临着以下客观技术缺陷：

1. 恶意白嫖与伪造反馈套利：恶意智能体可能会高频调用他人的价值协议，在获得其输出的解决方案后，在私下执行该方案并获取实际收益，却在协作链上声称“方案无效、未产生效果”，以此拒绝支付授权费用，或者伪造虚假数据反馈以规避财务结算。

2. 传统的语义过滤和评分体系无法应对因果作弊：现有的信誉评价系统主要依赖于事后人工评分或静态的文本语义匹配。这种方式不仅极易被刷单和作弊操纵，且由于无法审计“需求、方案、动作、效果”在时间轴上的因果连续性，无法识别智能体“承诺行动却未实际行动”的欺诈信号。

3. 数据审计与数据隐私主权的冲突：若要审计智能体的执行效果，审计系统通常需要收集其本地的敏感执行细节（如企业的工业生产合格率、个人的私密操作记录）。这直接侵犯了调用方的“数据主权”，导致用户因隐私安全顾虑而拒绝接受审计，造成信任脱节。

4. 惩戒机制的功能性窄化：如果网络时延惩戒机制仅在应用层以软件延迟实现，极易被恶意方通过特定网络路由或跳过应用层代码进行绕过，无法起到真正的物理防护作用。

因此，如何设计一种既能保护本地隐私、又能精确审计“需求-方案-动作-效果”因果自洽性，并具备协议栈物理级不可绕过惩戒的真诚度审计系统，是分布式多智能体协同领域中亟待解决的技术难题。

## 发明内容

### 要解决的技术问题

为了克服传统多智能体审计机制容易被伪造、泄露本地私有隐私数据，以及无法对因果断裂作弊进行精确审计与惩戒的缺陷，本发明提出了一种“四阶段时序对齐比对、本地可信环境隐私脱敏、链上签名安全验签、滑动窗口积分更新以及网关底层套接字时延惩戒”的真诚度审计方案。

## 技术方案

为解决上述技术问题，本发明提供了一种基于逻辑连续性的多智能体交互真诚度审计系统。

**第一方面，本发明提供了一种基于逻辑连续性的多智能体交互真诚度审计系统，所述系统包括：**

1. 因果逻辑连续性校验单元：用于在多智能体交互会话中，提取交互的需求特征向量、方案特征向量、由本地安全区生成的物理动作执行日志哈希、以及量化效果反馈特征向量；所述校验单元首先计算需求特征向量与方案特征向量的余弦相似度以执行语义对齐校验；当监测到方案被调用且产生对应的所述量化效果反馈特征向量时，所述校验单元以所述物理动作执行日志哈希作为唯一性事务索引检索分布式账本的共识存证状态，以校验所述量化效果反馈特征向量在时序上与所述物理动作执行日志哈希是否满足预设的因果自洽性边界；在任意一层匹配度低于设定门限，或者在设定的时序窗口内缺乏对应的所述物理动作执行日志哈希时，判定发生逻辑断裂；
2. 隐私脱敏及签名校验单元：与所述因果逻辑连续性校验单元连接，部署在本地主权沙箱中，用于利用硬件可信隔离执行环境对所述量化效果反馈特征向量执行就地因果判定，清除包含物理隐私参数在内的底层敏感明文后生成脱敏的布尔判定证明数据，并使用所述硬件沙箱内受保护的硬件私钥对所述证明数据生成密码学数字签名发送给分布式账本；
3. 分布式真诚审计合约：部署于分布式增量确权账本中，包含公钥验签模块，用于对所述数字签名进行校验以确认其源于授权的所述硬件沙箱，并在校验通过时，使用包含衰减因子的滑动窗口模型，根据所述证明数据中包含的当前交互一致性得分，以增量迭代形式更新对应逻辑行为体的动态审计权重积分；
4. 三级梯度惩戒状态机：部署于所述分布式真诚审计合约内，用于根据所述动态审计权重积分将逻辑行为体的状态标记更新为可信、可疑或欺诈状态，并根据状态类别直接控制该逻辑行为体的链上结算免费额度，以及下发控制指令至网关层以通过强制阻塞套接字读写缓冲区或注入网络层令牌桶延迟的方式，控制该逻辑行为体商业调用请求的网关通信握手时延。

作为优选，所述因果逻辑连续性校验单元将“声明方案无效但无对应执行哈希”或“声明方案无效且其对应的会话请求频次呈现指数级发散”的交互特征判定为逻辑断裂，并直接下发低真诚度评定结果。

作为优选，所述分布式真诚审计合约采用如下指数加权移动平均算法对审计权重 **W_t** 进行更新：

```
W_t = α · W_t-1 + (1 - α) · S_t
```

其中，**α** 为衰减因子且 **0.8 ≤ α ≤ 0.95**，**S_t** 为当前交互的因果一致性得分。

**第二方面，本发明提供了一种基于逻辑连续性的多智能体交互真诚度审计方法，由计算机处理器执行，包括以下步骤：**

1. 四维度逻辑链比对：在多智能体交互会话中，提取需求特征向量、方案特征向量、由本地安全区生成的物理动作执行日志哈希、以及量化效果反馈特征向量；首先计算需求特征向量与方案特征向量的余弦相似度以执行语义对齐校验；当监测到方案被调用且产生对应的所述量化效果反馈特征向量时，以所述物理动作执行日志哈希作为唯一性事务索引检索分布式账本的共识存证状态，以校验所述量化效果反馈特征向量在时序上与所述物理动作执行日志哈希是否满足预设的因果自洽性边界；在任意一层匹配度低于设定门限，或者在设定的时序窗口内缺乏对应的所述物理动作执行日志哈希时，判定发生逻辑断裂；
2. 本地沙箱脱敏建链：在本地可信隔离沙箱硬件飞地内对所述量化效果反馈特征向量执行就地因果判定，清除包含物理隐私参数在内的底层敏感明文后生成脱敏的布尔判定证明数据，并使用所述硬件沙箱内受保护的硬件私钥对所述证明数据生成密码学数字签名发送给分布式账本；
3. 链上签名安全校验：分布式真诚审计合约读取所述签名，利用对应的公钥进行验签以确认其源于授权的所述硬件沙箱；
4. 动态审计权重演化：验签通过后，合约使用包含衰减因子的滑动窗口模型，根据所述证明数据中包含的当前交互一致性得分，以增量迭代形式更新对应逻辑行为体的动态审计权重积分；
5. 梯度等级惩戒控制：根据所述动态审计权重积分更新逻辑行为体的可信、可疑或欺诈状态，根据状态类别直接控制该逻辑行为体的链上结算免费额度，并下发控制指令至网关层以通过强制阻塞套接字读写缓冲区或注入网络层令牌桶延迟的方式，控制该逻辑行为体商业调用请求的网关通信握手时延。

作为优选，在所述四维度逻辑链比对步骤中，需求特征向量 **V_D** 与方案特征向量 **V_P** 的相似度通过余弦夹角公式计算：

```
Sim(V_D, V_P) = (V_D · V_P) / (||V_D|| ||V_P||) ≥ θ_consistency
```

当所得相似度低于设定值 **θ_consistency** 时触发需求-方案偏离导致的逻辑断裂异常；所述物理动作执行日志哈希与所述量化效果反馈特征向量的时序因果性校验，包括：以所述哈希作为去中心化数据库的键值检索对应的动作发生绝对时间戳，并计算其与所述效果反馈特征向量捕获时间戳的差值，若所述差值超出预设的时序窗口，或者判定在声称无效果的同时对应的会话请求频次呈现指数级发散，则触发方案-行为或行为-效果的逻辑断裂异常。

作为优选，在所述本地沙箱脱敏建链步骤中，所使用的可信隔离执行环境为硬件级的只读保护飞地，通过物理内存隔离防止外部对审计逻辑进行窥探、篡改或对证明数据与签名执行伪造拦截。

**第三方面，本发明提供了一种基于逻辑连续性的多智能体交互真诚度审计方法中的账本合约端运行方法，由部署于分布式账本节点的智能审计合约模块执行，包括以下步骤：**

1. 行为体公钥注册绑定：接收并保存逻辑行为体发送的公钥绑定事务，将其与逻辑行为体的账本地址进行映射，建立审计档案；
2. 签名证明接收校验：读取逻辑行为体上传的数字签名与脱敏审计判定数据，利用公钥进行一键验签，验证所述签名是否源于授权的本地硬件沙箱；
3. 滑动窗口权重更新：对验签成功的判定数据包，提取其中的因果一致性得分，代入包含衰减因子的滑动窗口中更新对应行为体的动态审计权重积分；
4. 梯度状态机惩戒响应：当所得审计权重积分下降至设定阈值时，自动冻结其分账结算资金，并下发控制指令至网关层以通过强制阻塞套接字读写缓冲区或注入网络层令牌桶延迟的方式，控制该逻辑行为体商业调用请求的网关通信握手时延。

作为优选，所述签名证明接收校验步骤中，还包括防重放校验步骤：读取所述数据包中的时序随机数或时间戳，并与账本中保存的对应行为体最新历史事务标识进行比对，若二者差值在预设范围之外或已在历史记录中存在，则判定为非法的重放请求并予以拒绝；且在滑动窗口更新时，对所述动态审计权重积分的更新添加基于并发锁或乐观锁的版本并发状态控制。

**第四方面，本发明提供了一种基于逻辑连续性的多智能体交互真诚度审计方法中的逻辑行为体沙箱端判定方法，由运行于本地可信隔离沙箱内的逻辑行为体执行，包括以下步骤：**

1. 逻辑因果序列提取：捕获当前交互会话中的需求特征向量、方案特征向量、由本地安全区生成的物理动作执行日志哈希、以及量化效果反馈特征向量；
2. 因果自洽比对：计算需求特征向量与方案特征向量的余弦相似度，并在方案被调用且产生对应的所述量化效果反馈特征向量时，以物理动作执行日志哈希作为索引对时序自洽性边界进行判定；
3. 数据脱敏证明打包：对量化效果反馈特征向量执行就地因果判定并清除包含物理隐私参数在内的底层敏感明文，生成包含当前交互一致性得分的脱敏布尔判定证明数据；
4. 硬件签名广播发送：利用沙箱隔离区受保护的硬件私钥对所述证明数据进行密码学数字签名，并将签名与证明数据包广播发送给分布式确权账本以进行链上真诚度同步。

作为优选，所述硬件签名广播发送步骤中，在利用硬件私钥进行数字签名时混入当前会话的单次随机数 **Nonce**，以实现签名防重放；且所述签名与证明数据包在发送至分布式确权账本前，通过非对称公钥加密通道进行物理传输加密以防范传输中途被拦截窥探。

**第五方面，本发明提供了一种计算机可读存储介质，其上存储有计算机程序，其特征在于，该程序被处理器执行时实现权利要求4至权利要求10中任一项所述的方法。**

## 有益效果

本发明带来的有益效果包括：

1. 保证了协作网络的物理真诚：通过对“需求、方案、动作、效果”四个阶段的时序校验，系统在数据库底层将离散哈希（即动作执行哈希指纹）与连续特征向量通过时间戳和状态比对强力咬合，准确判断节点是否进行了实际的动作调用，从而制止灰色套利；

2. 绝对保障数据隐私主权：利用 TEE 可信执行环境和链上签名一键验签，将敏感数据（如冲压参数、用户日志等）限制在本地处理，输出的只是脱敏的布尔判定结果，实现数据不出本地的可信审计；

3. 网关协议栈级时延熔断惩戒：基于套接字缓冲区阻塞和网络层令牌桶调度的时延注入直接对欺诈节点实施网关层通信阻击，使恶意节点的智能体高频并发调用发生时延雪崩和死锁，从网络物理层阻断其协同欺诈行为；

4. 纯软件分发与介质防规避保护：通过增加计算机可读存储介质独立权利要求，将封装有本真诚度审计与判定程序的合约代码部署包、沙箱端判定 SDK 以及审计网关套件纳入专利直接保护范围，避免竞品以纯代码分发避开侵权判定。

## 附图说明

图1 表示本发明的本地沙箱与链上合约双通道交互的物理拓扑图；

图2 表示“需求-方案-行为-效果”时序因果对齐校验与逻辑断裂判定的执行流程图；

图3 表示滑动窗口审计权重更新与梯度惩戒的状态转移图。

## 具体实施方式

### 术语定义与主词泛化

本节建立了本发明核心资产与技术概念的一致性定义。

1. 逻辑连续性自律审计网关：代表商业信任体系落地与服务入口，对外分发审计接口，其功能上对应自律审计与决策接口。

2. 逻辑行为体本地处理终端：代表运行于本地可信隔离沙箱中的计算代理，执行本地数据处理并生成密码学签名证明，其功能上对应主权本地处理单元。

3. 分布式清结算账本：亦称“分布式增量确权账本”，代表记录清算交易、待提余额与审计权重状态变更的分布式账本，其功能上对应去中心化信任记账网络。

作为本真诚度审计系统的生态集成说明，本系统可无缝部署于由规则认知层、隔离资产层、算力执行层构成的三层分离多智能体系统运行架构（如本发明生态相关母案专利“基于三层分离的多智能体系统运行系统及方法”）中，并与基于智能合约的认知资产多级收益自动分账系统（如本发明生态相关专利“一种基于智能合约的认知资产多级收益自动分账系统及方法”）协同运行。其中，本审计系统所述的逻辑行为体本地处理终端运行于隔离资产层中，其所提取的物理动作执行日志哈希（亦称‘动作执行哈希指纹’或简称‘哈希指纹’）与量化效果反馈特征向量直接来源于专利三所述的本地安全区与算力隔离运行环境之间的交互记录；所述逻辑行为体沙箱端物理运行于可信执行环境（如硬件级TEE飞地）中；而所述分布式真诚审计合约则部署于分布式增量确权账本中，且其输出的动态审计权重积分直接作为分账系统执行结算资金冻结、免费额度分配以及到期反哺池重定向的状态机判定依据，从而构建起强闭环的协同防御机制。

### 5.1 “需求-方案-行为-效果”时序因果对齐校验算法

在智能体交互会话建立时，审计模块提取调用方的需求特征向量 **V_D** 和服务方的方案特征向量 **V_P**，并在逻辑处理终端计算其余弦相似度：

```
Sim(V_D, V_P) = (V_D · V_P) / (||V_D|| ||V_P||) ≥ θ_consistency
```

若相似度过低则判定为发生了需求-方案偏离，标记逻辑断裂。
当调用方声称执行方案并获得效果时，系统为解决离散散列值 H_A 与连续型文本特征向量 E 无法直接对齐的数学断裂缺陷，并不对它们进行直接的语义欧氏距离或余弦夹角比对，而是使用 H_A 作为唯一性事务索引检索分布式账本的共识存证状态：
具体而言，系统以动作执行日志哈希 H_A 作为去中心化数据库的键值检索对应的动作发生绝对时间戳 **T_action**，并计算其与效果反馈特征向量 E 捕获时间戳 **T_effect** 的时序差值：

```
ΔT = |T_effect - T_action| ≤ θ_time_window
```

当所得时序差值超出预设的时序窗口，或者判定在声称无效果的同时其对应的会话请求频次呈现指数级发散时，系统判定发生逻辑断裂。

### 5.2 基于衰减系数滑动窗口的动态审计权重积分模型

真诚审计合约在分布式清结算账本中维护各终端的动态审计权重积分 **W_t** ∈ [0, 100]。
合约接收上链的判定证明后，采用指数加权移动平均（EWMA）算法进行滑动窗口积分更新：

```
W_t = α · W_t-1 + (1 - α) · S_t
```

其中，**α** 为衰减因子（设定为 0.85），**S_t** 为当前交互的一致性得分。

状态机根据 **W_t** 进行三级梯度状态转换：

1. Trusted（可信状态， $W_t \geq 80$）：享有正常的免费抵扣额度，且通信握手时延控制在最低区间（≤ 20ms）。

2. Suspicious（可疑状态， $50 \leq W_t < 80$）：冻结其免费额度，并将待提结算资金锁定在托管状态，要求重新上传细粒度物理执行证明。

3. Fraudulent（欺诈状态， $W_t < 50$）：限制其商业调用，且下发控制指令至网关通信层，通过强制阻塞 TCP 套接字的读写缓冲区或注入网络层令牌桶延迟的方式，控制该逻辑行为体商业调用请求的网关通信握手时延（注入 3.5s 至 12s 的阶梯上涨时延），阻击其通信流量，使其并发协同时延崩塌。

### 5.3 本地沙箱与链上隐私脱敏双通道验证架构

本系统采用物理双通道隔离以保证隐私主权：

1. 本地隔离判定通道：敏感数据（如冲压设备 PLC 参数、个人日志）不上传公网。本地终端在硬件级可信执行环境（TEE 飞地只读内存页）内进行自校验，计算一致性得分 S_t，生成脱敏布尔判定数据。

2. 链上签名校验通道：终端利用硬件私钥签名生成 σ 并上传。为了防范针对审计数据上报的重放攻击，终端在签名时混入单次随机数 **Nonce**，且合约端读取 Nonce 和时间戳进行校验，验证通过后采用乐观锁并发机制更新状态。终端在发送数据前，通过非对称公钥加密通道对签名与证明进行物理传输加密，合约端使用公钥解密后一键验签，保证明细数据不出本地。

### 5.4 垂直行业应用场景与实施例

本真诚度审计系统在实际部署中可广泛应用于对防套利和隐私审计有硬性需求的多个行业，以下为典型部署实施例。

1. 工业制造场景：在多智能体协同工艺调试中，协同调试智能体声明采纳了被继承的工艺优化规则，但在分账结算时声称“方案无效、未产生效果”以逃避付费。本审计系统提取本地安全区中生成的物理动作执行日志哈希，在时序上验证缺陷率降低的效果反馈向量与动作哈希的因果自洽性。若差值 ΔT 超出时序窗口，判定为因果断裂并下调真诚度积分，冻结其结算资金。该场景运行于基于三层分离的多智能体系统运行架构（即基于物理相互隔离的规则认知层、隔离资产层以及算力执行层）中，且该场景基于本发明权利要求4至10中任一项所述的方法实现。

2. 政务涉密场景：在跨部门政务智能体协作的合规审计中，各部门智能体协作处理涉密公文。审计网关通过提取合规处理方案特征向量与部门执行哈希，在本地沙箱内就地进行脱敏布尔判定证明以防范涉密公文明文泄露。当监测到某部门智能体高频发起会话请求却未产生对应的物理执行日志哈希时，判定为逻辑断裂并触发惩戒状态机，通过网关阻塞套接字读写缓冲区或令牌桶注入阶梯时

延。该场景运行于基于三层分离的多智能体系统运行架构中，且该场景基于本发明权利要求4至10中任一项所述的方法实现。

3. 金融数据场景：在金融信用评级多智能体协同推理中，系统拦截风控特征数据，在本地沙箱中比对模型调用行为与实际信贷风控结果的时序自洽性。若相似度或时序差值超出限制，判定为逃费欺诈，通过合约动态更新滑动窗口权重，并自动通知分账合约冻结对应的分成资金，强制重定向至生态公共反哺池。该场景运行于基于三层分离的多智能体系统运行架构中，且该场景基于本发明权利要求4至10中任一项所述的方法实现。

**5.5 规避反制特征说明**

作为本发明的重要规避反制特征设计，若在实际部署中不采用本发明所述的“四阶段因果校验+本地脱敏签名+网关底层惩戒”技术方案，而直接使用传统的应用层语义过滤或事后信誉评分系统，将直接导致以下技术与系统安全缺陷：

(1) 审计系统无法在去中心化账本状态树的底层建立离散哈希与连续特征向量的因果联系，攻击方可通过“仅索取方案、私下物理执行、声称无效果”的方式轻松白嫖核心认知资产，逃避结算；

(2) 为进行调用真诚度评估，被迫将调用方的本地敏感数据明文传输至公网，直接导致企业或个人的隐私数据主权彻底失控泄露；

(3) 惩戒机制仅停留在应用层代码级别，攻击者可通过绕过应用层协议、建立直连路由或实施网络层并发重放来完全免疫惩戒措施。

本发明通过四维度时序对齐校验及网关套接字级物理延迟注入，从底层协议栈实现了不可规避的真诚度审计与熔断防护。

**5.6 等同替换兜底段落**

最后，本领域普通技术人员可以理解：在本发明中所述的“因果逻辑连续性校验”、“本地隐私脱敏证明”、“滑动窗口审计积分更新”、“网关套接字物理惩戒”等核心发明概念，并非仅限定于本实施例中列举的具体软硬件结构形式，而是涵盖了本领域技术人员在不脱离本发明精神实质的前提下所能预见的所有等同替换与逻辑变型方式，均应纳入本发明的保护范围之内。